

Sistema RAG para Consulta Agronómica

Documentación Técnica del Proyecto

Arquitectura, componentes y flujo de procesamiento sobre base documental de 30 años

Versión: 1.0 — Borrador
técnico

Fecha: Mayo 2026

Destinatario: Ing. Agr. /
Equipo técnico

Clasificación: Uso interno

1. Introducción y Contexto del Proyecto

El presente documento describe la arquitectura técnica de un sistema de inteligencia artificial diseñado para aprovechar la base documental del INTA acumulada durante las últimas tres décadas. El sistema permite a productores, técnicos y estudiantes consultar en lenguaje natural sobre prácticas agronómicas, con respuestas fundamentadas en fuentes científicas validadas.

1.1. Problema que resuelve

El INTA cuenta con un volumen extraordinario de conocimiento técnico — anuarios, ensayos de campo, boletines regionales, informes de zonas agroecológicas — que permanece subutilizado por barreras de acceso y búsqueda. Un productor que necesita saber qué pastura conviene en otoño en suelos húmedos del sur de Buenos Aires no tiene forma eficiente de consultar ese acervo.

1.2. Solución propuesta

Un sistema de tipo RAG (Retrieval-Augmented Generation) que indexa semánticamente la documentación del INTA y responde consultas en lenguaje natural, con validación experta incorporada al flujo de trabajo. El sistema aprende y mejora con cada interacción correctamente validada.

2. Arquitectura Técnica: Componentes Clave

A continuación se describen los ocho componentes fundamentales del sistema, con su definición técnica, su rol específico en el proyecto y ejemplos concretos del dominio agronómico.

□ 2.1. Dataset

Definición

Conjunto de datos estructurado que alimenta el aprendizaje y la evaluación del sistema. Incluye pares pregunta-respuesta, correcciones de expertos y métricas de calidad.

Aplicación en el proyecto

El dataset del proyecto se construye de forma incremental: cada interacción entre un usuario y el sistema, una vez validada por un técnico del INTA, se incorpora como nuevo ejemplo de entrenamiento.

Ejemplo: Pregunta: '¿Qué pastura conviene en otoño?' → Respuesta validada: 'Festuca + trébol blanco en suelos húmedos del sur bonaerense (INTA Balcarce, 2018)'

□ **Clave:** Es el activo más valioso y diferencial del proyecto. Su calidad determina la calidad del sistema.

□ 2.2. Chunking (Segmentación de documentos)

Definición

Proceso de división de documentos extensos en fragmentos de tamaño controlado. Cada fragmento es una unidad semántica coherente que puede ser recuperada de forma independiente.

Aplicación en el proyecto

Los anuarios y publicaciones del INTA, muchos de ellos en formato PDF de cientos de páginas, se segmentan en bloques de entre 300 y 500 tokens. El tamaño se calibra para balancear precisión de recuperación y contexto suficiente para generar respuestas completas.

Ejemplo: Un PDF de 200 páginas sobre manejo de pasturas se transforma en aproximadamente 500 fragmentos temáticos, cada uno con su referencia bibliográfica original.

□ **Clave:** La granularidad del chunking impacta directamente en la precisión de las respuestas. Un chunk demasiado grande introduce ruido; uno demasiado pequeño pierde contexto.

□ 2.3. Embeddings (Representaciones vectoriales)

Definición

Transformación de texto en vectores numéricos de alta dimensión que capturan el significado semántico del contenido. Generados por modelos de lenguaje especializados.

Aplicación en el proyecto

Cada fragmento del corpus INTA se convierte en un vector numérico (típicamente de 768 a 1536 dimensiones) y se almacena en una base de datos vectorial. La similitud entre vectores refleja similitud de significado, no de palabras exactas.

Ejemplo: *'siembra en otoño' y 'implantación otoñal' producen vectores cercanos en el espacio semántico, permitiendo que una consulta con cualquiera de los términos encuentre ambos fragmentos.*

□ **Clave:** Permiten búsqueda por significado en lugar de por palabras clave. Fundamental para capturar la diversidad terminológica del lenguaje agropecuario.

□ 2.4. RAG — Retrieval-Augmented Generation

Definición

Arquitectura de IA que combina recuperación de información (búsqueda en base de datos) con generación de texto (modelo de lenguaje). El modelo no responde desde su memoria de entrenamiento, sino desde documentos recuperados en tiempo real.

Aplicación en el proyecto

Cuando un productor realiza una consulta, el sistema: (1) convierte la pregunta en un vector, (2) busca los fragmentos más relevantes del corpus INTA, (3) entrega esos fragmentos como contexto al modelo de lenguaje, (4) el modelo genera una respuesta fundamentada en esa fuente.

Ejemplo: Consulta: '¿Cuándo aplicar herbicida en verdeo de invierno?' → El sistema recupera 4 fragmentos relevantes de publicaciones INTA → El modelo responde citando esas fuentes específicas.

□ **Clave:** Es el núcleo de la confiabilidad del sistema. El modelo no inventa: responde con base en documentación verificable.

□ 2.5. Fine-tuning (Ajuste fino del modelo)

Definición

Proceso de reentrenamiento de un modelo base preexistente usando datos específicos del dominio. El modelo adapta sus parámetros para responder mejor en el contexto agronómico regional.

Aplicación en el proyecto

Una vez acumulado un dataset de calidad suficiente (mínimo recomendado: 500-1000 pares validados), se realiza un ciclo de fine-tuning sobre un modelo base open-source. El resultado es un modelo que habla el idioma técnico del agro local y regional.

Ejemplo: Modelo base + 800 pares pregunta-respuesta validados por técnicos INTA = modelo especializado en agronomía pampeana con comprensión del vocabulario regional.

□ **Clave:** Se ejecuta DESPUÉS de construir un dataset robusto. El fine-tuning sobre datos pobres produce un modelo inferior al modelo base.

□ 2.6. Ranking semántico (Búsqueda y re-ranking)

Definición

Proceso de ordenamiento de los fragmentos recuperados por relevancia respecto a la consulta. Combina similitud vectorial con criterios adicionales como recencia, especificidad geográfica y fuente.

Aplicación en el proyecto

El sistema recupera inicialmente los 10-20 fragmentos más similares vectorialmente y aplica un re-ranking que considera factores como la región agroecológica, el período del año y la jerarquía de la fuente (ensayo experimental vs. divulgación).

Ejemplo: Consulta: '¿Qué sembrar en invierno en suelos arcillosos?' → Se recuperan 15 fragmentos → Re-ranking selecciona los 4 más relevantes para la región y el contexto estacional.

□ **Clave:** Es el 'cerebro selectivo' del RAG. La calidad del ranking determina la calidad del contexto que recibe el modelo.

□ 2.7. Modelo base

Definición

Modelo de lenguaje preentrenado sobre corpus masivos de texto general. No se construye desde cero; se reutiliza y especializa. Opciones open-source relevantes: Mistral 7B, Gemma 2B/7B, LLaMA 3.

Aplicación en el proyecto

El proyecto selecciona un modelo base eficiente que pueda desplegarse en infraestructura local o de bajo costo (GPU accesible o CPU con cuantización). La elección balancea capacidad de razonamiento, costo de inferencia y requerimientos de hardware.

Ejemplo: *Mistral 7B cuantizado (4-bit) corre en una GPU de 8GB VRAM, viable para un servidor institucional estándar o incluso una workstation de escritorio.*

□ **Clave:** No es necesario desarrollar un modelo propio. La diferenciación está en el dataset INTA, no en el modelo base.

□□ 2.8. Human-in-the-loop (Validación humana)

Definición

Incorporación sistemática de revisión experta en el flujo de generación y aprendizaje. Los técnicos o docentes revisan, corrigen y aprueban respuestas antes de que queden disponibles en el sistema.

Aplicación en el proyecto

Cada respuesta generada pasa por una interfaz de revisión donde un técnico del INTA puede: (a) aprobar sin cambios, (b) corregir parcialmente, (c) rechazar y reescribir. La versión validada alimenta el dataset.

Ejemplo: *El sistema genera: 'Aplicar glifosato 5L/ha en lote con presencia de gramón'. El técnico corrige: 'Aplicar glifosato 4L/ha en pre-siembra, considerando el umbral de tolerancia regional para gramón'. → Corrección entra al dataset.*

□ **Clave:** Transforma el sistema de experimental a institucional. Sin esta validación, el sistema no puede desplegarse con respaldo técnico-científico.

3. Flujo Completo de Procesamiento

El siguiente diagrama describe la secuencia de operaciones desde la ingesta documental hasta la acumulación de conocimiento validado en el dataset.

1	Documentación INTA	30 años de publicaciones, anuarios, ensayos de campo, boletines técnicos y resultados experimentales digitalizados.
2	Chunking	Cada documento se divide en fragmentos de texto de tamaño óptimo (aprox. 300-500 tokens) para permitir recuperación precisa.
3	Embeddings	Cada fragmento se convierte en un vector numérico (representación matemática semántica) y se almacena en una base de datos vectorial.
4	Consulta del usuario	El productor o técnico ingresa su pregunta en lenguaje natural desde la interfaz web o móvil.
5	RAG – Recuperación	El sistema busca los fragmentos más semánticamente relevantes usando similitud de coseno entre vectores.
6	Generación de respuesta	El modelo de lenguaje recibe los fragmentos recuperados como contexto y genera una respuesta fundamentada.
7	Validación humana	Un técnico o docente del INTA revisa, corrige y valida la respuesta antes de que quede disponible en el sistema.
8	Dataset acumulativo	Las respuestas validadas se incorporan al dataset de entrenamiento para futuras iteraciones de fine-tuning.

4. Marco Conceptual: Analogía Pedagógica

Para facilitar la comunicación del proyecto a audiencias no técnicas (directivos, productores, estudiantes), se propone la siguiente analogía: el sistema de IA funciona como un alumno muy estudioso que aprendió de los libros del INTA, sabe buscar en la biblioteca y tiene un docente que lo corrige.

Componente IA	Analogía pedagógica	Rol técnico
Dataset	Libros de texto y bibliografía técnica	Base del conocimiento estructurado
RAG	Buscar en la biblioteca antes de responder	Recuperación de información contextual
Fine-tuning	Estudiar para un examen específico	Especialización en agronomía regional
Human-in-the-loop	El docente corrigiendo al alumno	Validación y mejora continua

Embeddings	<i>Índice temático del libro</i>	Organización semántica del conocimiento
Chunking	<i>Dividir el manual en capítulos y secciones</i>	Granularidad para búsqueda precisa

Frase institucional del proyecto

"La IA no sabe del campo. Nosotros le enseñamos con datos del INTA, la controlamos con expertos y la mejoramos con el uso."

5. Hoja de Ruta Técnica Recomendada

Fase 1 — Ingesta y preparación del corpus (semanas 1-4)

- Digitalización y catalogación de publicaciones INTA en formato PDF/texto
- Definición de metadatos: año, zona agroecológica, tipo de cultivo, autor
- Configuración del pipeline de chunking con herramientas open-source (LangChain, LlamaIndex)
- Generación de embeddings y carga en base de datos vectorial (ChromaDB, Weaviate o pgvector)

Fase 2 — Prototipo RAG funcional (semanas 5-8)

- Selección e integración del modelo base (Mistral 7B o equivalente)
- Implementación del pipeline de recuperación y generación
- Desarrollo de interfaz de usuario básica para consultas
- Implementación del módulo de human-in-the-loop para técnicos validadores

Fase 3 — Acumulación de dataset y evaluación (semanas 9-16)

- Apertura del sistema a usuarios piloto (técnicos INTA, docentes, productores seleccionados)
- Proceso sistemático de validación y corrección de respuestas
- Métricas de evaluación: precisión de recuperación (recall@k), calidad de respuesta (BLEU, ROUGE), satisfacción de usuario
- Identificación de vacíos temáticos en el corpus

Fase 4 — Fine-tuning y escala (a partir de semana 17)

- Fine-tuning sobre dataset acumulado (mínimo 500 pares validados)
- Evaluación comparativa: modelo base vs. modelo fine-tuned
- Despliegue en producción con monitoreo continuo
- Expansión del corpus documental y nuevas zonas agroecológicas

6. Consideraciones de Infraestructura

6.1. Opción A — Despliegue local (alta soberanía de datos)

- Servidor con GPU NVIDIA (mínimo 8GB VRAM para modelos cuantizados)
- Almacenamiento: 1-2TB SSD para corpus documental y base vectorial
- Sistema operativo: Ubuntu Server 22.04 LTS
- Ventaja: control total de los datos y sin costos por inferencia

6.2. Opción B — Nube híbrida (escalabilidad + costo moderado)

- Base vectorial en nube (Pinecone, Weaviate Cloud)
- Modelo de lenguaje vía API (Anthropic Claude, OpenAI) o despliegue serverless
- Corpus documental en storage institucional (MinIO, S3)
- Ventaja: escalabilidad sin inversión inicial en hardware

7. Glosario Técnico de Referencia

Término	Definición
Token	Unidad básica de texto procesada por el modelo (aproximadamente 0.75 palabras en español). Un documento de 1000 palabras equivale a ~1300 tokens.
Vector / Embedding	Representación numérica de un texto en un espacio de alta dimensión. Textos semánticamente similares tienen vectores cercanos (alta similitud de coseno).
Base de datos vectorial	Sistema de almacenamiento especializado en búsqueda por similitud entre vectores. Ejemplos: ChromaDB, Weaviate, pgvector (extensión PostgreSQL).
LLM	Large Language Model. Modelo de lenguaje de gran escala entrenado en corpus masivos de texto. Capaz de generar, resumir y razonar sobre texto.
Inferencia	Proceso de generar una respuesta usando el modelo entrenado. Distinto del entrenamiento (ajuste de parámetros).
Cuantización	Técnica de compresión del modelo que reduce su precisión numérica (ej: de 32-bit a 4-bit) para disminuir requerimientos de memoria manteniendo buena calidad.
Pipeline	Secuencia automatizada de procesos: ingesta → chunking → embedding → recuperación → generación → validación.
Similitud de coseno	Métrica que mide el ángulo entre dos vectores. Valor entre 0 (sin relación) y 1 (idénticos). Base matemática de la búsqueda semántica.
Prompt	Instrucción o consulta entregada al modelo de lenguaje. En el sistema RAG, incluye la pregunta del usuario y los fragmentos recuperados del corpus.
Temperatura	Parámetro que controla la aleatoriedad de las respuestas del modelo. Valor bajo (0.1-0.3): respuestas más deterministas y precisas. Recomendado para consultas técnicas.